Einfach mal ausprobieren

Korpus Einfaches Deutsch für daten-geleitetes Fremdsprachenlernen auf Anfängerniveau

Dr. Daniel Jach

Pädagogische Universität Shanghai
上海师范大学

3. Juni 2021, online, Nachwuchskonferenz der 48. Jahrestagung DaF/DaZ

Motivation

- Quantification in large amounts in linguistics and EFL ...
  - *Quantitative Turn* [7]
  - *WordSmith Tools* [14]
  - *Academic Phrasebank* [11]
  - *Kibbitzers* [9]
  - ...

- ... aber noch kaum in DaF/DaZ ...
  - *GeWiss* [3]
  - *ZuMult* und Mirkohörübungen [15]

... auch aus Mangel an didaktisch geeigneten Korpora

Übersicht

Was ist KED?

Für was und für wen ist KED gut?

Wo bekomme ich und wie benutze ich KED?

Was ist KED?

KED ist...

KED (**K**orpus **E**infaches **D**eutsch) ist eine große digitale Sammlung von Texten aus bildungssprachlichen Genres auf einfachem Deutsch.

- Was ist Bildungssprache?
- Was ist einfaches Deutsch?

Was ist Bildungssprache?

Bildungssprache ist in diesem Verständnis die Varietät, die für Bildungskontexte angemessen und in diesen funktional ist. [5]

Öffentliche Sprache

(Konzeptionell) schriftsprachlich

KED enthält Texte bildungssprachlicher Genres, z.B.

- Lexikoneinträge
- Anleitungen
- Schulische Texte
- Erzählungen
- Öffentliche Texte

Was ist Einfaches Deutsch?

Einfaches Deutsch ist z.B. definierbar als...

- nicht komplexes Deutsch [Sprachliche Komplexität, 13]
- leichtes Deutsch [Leichte Sprache, 10, 12]

Einfach ist das, was SprachnutzerInnen gebrauchen, wenn sie beabsichtigen, sich einfach zu äußern.

KED enthält Texte, die ...

> *für Lesende geschrieben sind, von denen die Schreibenden vermuten, dass sie noch nicht die nötigen Lesefähigkeiten zur Lektüre bildungssprachlicher Texte entwickelt haben oder diese nicht entwickeln können.*
>
> *ohne sprachpädagogische Absicht geschrieben sind.*

Was genau ist drin in KED?

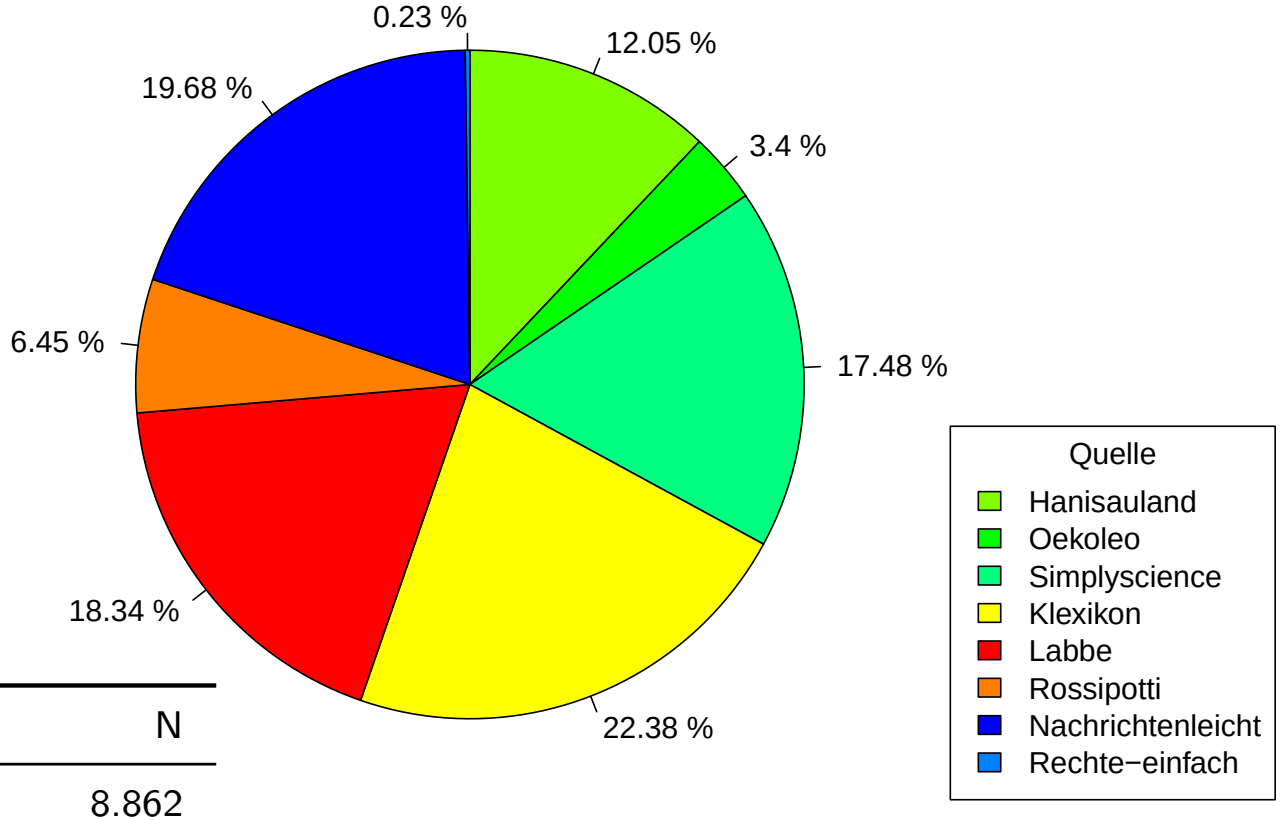

	N
Texte	8.862
Wörter	3.698.372

...von verschiedenen Internetseiten, gescrapt mit *Sketch Engine* (https://www.sketchengine.eu/).

Für was und für wen ist KED gut?

KED ist gedacht als Ressource für...

- **daten-geleitetes Deutsch-als-Fremdsprache-Lernen** auf Anfängerniveau und richtet sich an DaF-Lernende und -Lehrende.
- die **Erforschung sprachlicher Komplexität** und richtet sich an linguistisch Forschende.

Daten-geleitetes Fremdsprachenlernen

Bei DDL („data-driven language learning“) nutzen Lernende digitale Korpus-Technologie, um die grammatischen Muster, Gebrauchsmuster und Chunks ihrer Zielsprache selbstständig zu entdecken [2, 8].

DDL...

- vermittelt sprachliche und technologische Fertigkeiten...
- induktiv, gebrauchsbasiert und...
- lerner-zentriert (entdeckendes Lernen).

- soll andere Lehransätze ergänzen, nicht ersetzen.

Beispiel: *überreden* vs *überzeugen* [8]

Vorbereitung Durchsuchen Sie KED nach Belegen für *überreden* und *überzeugen*.

Linker Kontext	**überreden/überzeugen** ...
konnte man die Japaner endgültig davon	**überzeugen**, dass ein Weiterkämpfen sinnlos
kann sein: Ein Mensch ist davon	**überzeugt**, dass alles auf der Welt eine
einmal verwechselt. Auch dann ist er	**überzeugt**, dass er es richtig weiß, obwohl
Darum war sie zutiefst davon	**überzeugt**, dass der Kapitalismus abgelöst
ich besser, bin aber nicht ganz	**überzeugt** davon. Da würde ich mir ein
willst. Niemand darf dich zum Sex	**überreden** oder zwingen. Niemand darf für Sex
ich Zorx gleich zu einem Waffenstillstand	**überreden** und mit ihm Pläne für eine
Vorhaben zu stören, indem sie Digory	**überreden** will, den Apfel zu stehlen und
und zum Kauf eines neuen Autos	**überreden** will. Und überzeugt ist, dass es
unempfänglich ist und versucht, sie zu	**überreden**, den Fluch von der Prinzessin zu nehmen
Frühlichts und Wächter des Himmels, dazu	**überreden**, eine List anzuwenden. Als Braut
Wird es ihm gelingen, Isabella zu	**überreden**, Kolumbus die Reise gen Westen zu
...	

Aufgabe Welche Unterschiede im Gebrauch von *überreden* und *überzeugen* erkennen Sie in den Belegen?

Beispiel: Wechselpräpositionen

Vorbereitung Durchsuchen Sie das KED-Teilkorpus *Nachrichtenleicht* nach Belegen für die drei häufigsten Wechselpräpositionen *in, an* und *auf*, gefolgt von einem definiten Artikel.

Linker Kontext	**Präposition + Artikel** ...
Staat auf den Britischen Inseln. Sie liegen	**in der** Nord-See. Die größte Insel heißt
Der Grüne Hügel ist eine Anhöhe	**in der** Stadt Bayreuth. Dort ließ der Komponist
dem Fahrzeug und schickt sie weiter	**an die** Forscher auf der Erde. Das ist
28 zu 24 für Kiel. Das Pokal-End-Spiel war	**in der** Stadt Hamburg. Mehr als
zeigen, wie schlimm das Leben	**in dem** Lager ist. Viele Hütten und Wohnungen sind
Regierung hat beschlossen: Sie beteiligt sich	**an der** Entschädigung von den Kunden
Eine Rakete kann sehr schnell	**in den** Himmel fliegen. Sie kann Astronauten
Obwohl es einen schweren Anschlag	**in der** Stadt Halle gegeben hat, sollen die
alle Regeln beachtet. Die Tische	**in dem** Restaurant haben weit genug auseinander
Eine Kita ist ein Ort,	**an dem** kleine Kinder spielen und lernen. Erzieher und
Land China gewesen. Viele Menschen	**auf der** ganzen Welt haben sich angesteckt,
...	

Aufgaben

1. Gruppieren Sie ähnliche Belege zusammen. Was haben die Belege gemeinsam?
2. Markieren Sie Artikel im Akkusativ rot, im Dativ grün. Wie sind Akkusative und Dativ über die Gruppen verteilt?
3. Mit welchen Verben und Präpositionen kommen Akkusativ bzw. Dativ besonders häufig vor?
4. Welche Präposition kommt besonders häufig vor? Welche Wörter kommen häufig zusammen vor?

Erforschung sprachliche Komplexität

Was bedeutet *sprachlich komplex*?

- Wort-, Satzlänge, Type-Token-Ratio [13], Relativsätze [4], ...
- Perspektive der SprachnutzerInnen (KED)

Korpus Einfaches Deutsch (KED) vs Leipzig Corpus Collection (LCC) [6]

Tabelle 1: Vergleich von KED und LCC

	Wortlänge	Satzlänge	Typen/Tokens
Zeitungsnachrichten (LCC)	5.24	16.36	0.14
Nachrichtenleicht (KED)	4.94	9.71	0.05
Wikipedia (LCC)	5.37	16.94	0.15
Klexikon (KED)	4.75	12.61	0.05

LCC = Leipzig Corpus Collection

Erforschung sprachliche Komplexität

Was bedeutet *sprachlich komplex*?

- Wort-, Satzlänge, Type-Token-Ratio [13], Relativsätze [4], ...
- Perspektive der SprachnutzerInnen (KED)

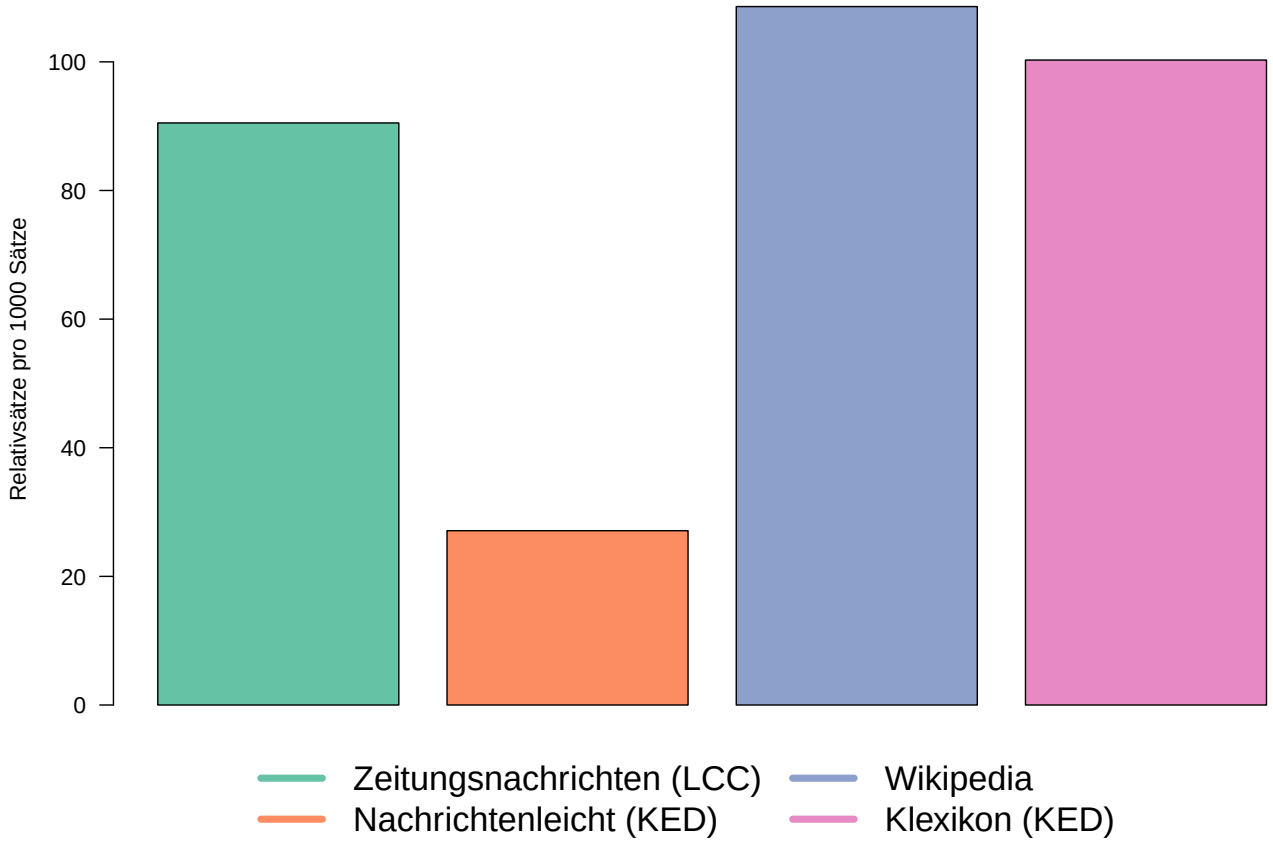

Abbildung 1: Vergleich von Relativsätzen in KED und LCC

Wo bekomme ich und wie benutze ich KED?

Wo bekomme ich und wie benutze ich KED?

1. KED herunterladen.
   https://daniel-jach.github.io/simple-german/simple-german.html
2. Konkordanzer *AntConc* von Anthony [1] herunterladen.
   https://www.laurenceanthony.net/software/antconc/
3. *AntConc* öffnen, KED laden, loslegen.

Vielen Dank für Ihre Aufmerksamkeit!

Literatur I

Lawrence Anthony. *AntConc (Version 3.5.8) [Computer Software]*. Techn. Ber. Tokyo, Japan, 2019. URL: https://www.laurenceanthony.net/software.

Thomas Cobb und Alex Boulton. „Classroom applications of corpus analysis“. In: *The Cambridge Handbook of English Corpus Linguistics*. Hrsg. von Douglas Biber und Randi Reppen. Cambridge, England: Cambridge University Press, 2015, S. 478–497.

C. Fandrych, C. Meißner und F. Wallner. „Das Potenzial mündlicher Korpora für die Sprachdidaktik: Das Beispiel GeWiss“. In: *Deutsch als Fremdsprache* 55.1 (2018), S. 3–13.

Edward Gibson. „The Dependency Locality Theory: A Distance-Based Theory of Linguistic Complexity“. In: *Image, Language, Brain*. Hrsg. von Alec Marantz, Yasushi Miyashita und Wayne O'Neil. Cambridge, MA: MIT Press, 2000, S. 95–126.

Ingrid Gogolin und Joana Duarte. „Bildungssprache“. In: *Handbuch Sprache in der Bildung*. Hrsg. von Jörg Kilian, Birgit Brouër und Dina Lüttenberg. Berlin, Deutschland: De Gruyter, 2016, S. 478–499. DOI: 10.1515/9783110296358. URL: https://doi.org/10.1515/9783110296358.

Dirk Goldhahn, Thomas Eckart und Uwe Quasthoff. „Building Large Monolingual Dictionaries at the Leipzig Corpora Collection: From 100 to 200 Languages.“. In: *Proceedings of the 8th International Language Resources and Evaluation (LREC'12)*. Hrsg. von Nicoletta Calzolari u. a. Istanbul, Turkey: European Language Resources Association (ELRA), 2012, S. 759–765.

Laura A. Janda, Hrsg. *Cognitive Linguistics: The Quantitative Turn: The Essential Reader*. Berlin, Germany: De Gruyter, 2013.

Tim Johns. „Should you be persuaded: Two samples of data-driven learning materials“. In: *Empirical Language Research* 4 (1991), S. 1–16.

Tim Johns. *Tim Johns' EAP Page*. 1996. URL: https://lexically.net/TimJohns/Kibbitzer/timeap3.htm#revision.

Gudrun Kellermann. „Leichte und Einfache Sprache – Versuch einer Definition“. In: *Aus Politik und Zeitgeschichte* 64.9–11 (2014), S. 7–10.

J. Morley. *Academic Phrasebank*. 2018. URL: http://www.phrasebank.manchester.ac.uk/.

Netzwerk Leichte Sprache. *Die Regeln für Leichte Sprache*. 2017. URL: https://www.leichte-sprache.org/wp-content/uploads/2017/11/Regeln_Leichte_Sprache.pdf.

Jessica Neumann und Tinghui Duhan. „Lesbarkeitsformeln zur Messung sprachlicher Komplexität in Schulbuchtexten“. In: *Der-Die-DaZ – Forschungsbefunde zu Sprachgebrauch und Spracherwerb von Deutsch als Zweitsprache*. Hrsg. von Britta Hövelbrinks u. a. 2018, S. 269–284. DOI: 10.1515/9783110582819-279. URL: https://doi.org/10.1515/9783110582819-279.

M. Scott. *Wordsmith Tools version 8*. Lexical Analysis Software. Stroud, 2020.

Franziska Wallner und Cordula Meißner. „Korpora gesprochener Sprache als Ressource für die Hörverstehensdidaktik: aktuelle Perspektiven“. In: *Online-Tagung Mikro-Hörübungen und authentische Hörmaterialien*. 2020. URL: https://www.uni-bamberg.de/fileadmin/germ-lingdaf2/Tagungsdokus/Wallner_Meissner_Abstract_Mikrohoeruebungen.pdf.